

11-3-2024

Aprendizaje Bayesiano

- Universidad de Colima - Campus Coquimatlán
- **Escuela:** Facultad de Ingeniería Mecánica y Eléctrica
- **Carrera:** Ingeniería en computación inteligente
- **Materia:** Analítica predictiva
- **Maestro:**
- **Autor:** Salma Jael Cortés Santa Ana
- **Semestre y grupo:** 8°B

Índice

Introducción:	2
Descripción:.....	2
Modalidades:.....	4
▪ Aprendizaje bayesiano ingenuo o Naïve Bayes.....	4
▪ Redes neuronales bayesianas	6
▪ Máquinas de vectores de soporte bayesianas.....	6
▪ Árboles de decisión bayesianos	6
Aplicaciones del aprendizaje Bayesiano	7
• Detección de fraude con tarjetas de crédito	7
• Filtrado de correo no deseado.....	8
• Diagnóstico médico.....	8
• Ayuda a los robots a tomar decisiones	8
• Reconstrucción de imágenes limpias a partir de imágenes ruidosas	8
Ejemplo.....	9
Conclusión o reflexión final.....	11
Referencia o bibliografía	12

Introducción:

El aprendizaje bayesiano, una herramienta poderosa en los campos de la inteligencia artificial y la estadística, ha ganado prominencia en la última década debido a su capacidad para modelar la incertidumbre y ajustar nuestros conocimientos a medida que recibimos nueva información. Es esencial en una variedad de aplicaciones, desde el filtrado de correo no deseado hasta el diagnóstico médico y la toma de decisiones robóticas.

Este trabajo explora los fundamentos del aprendizaje bayesiano, desde el teorema de Bayes hasta su aplicación en algoritmos como el Naïve Bayes, redes neuronales bayesianas, máquinas de vectores de soporte bayesianas y árboles de decisión bayesianos. Además, examina diversas aplicaciones del aprendizaje bayesiano en campos como la detección de fraudes, el filtrado de correo no deseado, el diagnóstico médico y la toma de decisiones en robótica, entre otros, y proporciona un ejemplo de cómo se implementa para resolver un problema de filtrado de correo no deseado.

Descripción:

El aprendizaje bayesiano, según Laura Noreña (2023), consiste en ajustar nuestras creencias sobre algo a medida que recibimos nueva información. Esto implica continuar refinando nuestras ideas basándonos en lo que aprendemos. Es como si tuviéramos una hipótesis inicial y la fuéramos actualizando con cada nueva observación.

Según Raúl López (2017), el aprendizaje bayesiano se representa a través del teorema de Bayes, el cual, describe cómo cambiamos nuestras creencias sobre el mundo cuando recibimos nueva información. López también señala que Bayes no afirmaba que el mundo fuera siempre incierto, ya que creía en la perfección divina. Más bien, Bayes argumentaba que aprendemos gradualmente sobre el mundo, aproximándonos cada vez más a la verdad a medida que acumulamos más evidencia.

A continuación, en la figura 1, se verá la fórmula del teorema de Bayes:




Figura 1. Imagen de la fórmula del teorema de Bayes. Pasos por ingeniería. (2021, March 25). TEOREMA DE BAYES (EXPLICACIÓN COMPLETA CON EJERCICIO) [Video]. YouTube. Recuperado el 10 de marzo de 2024, de <https://www.youtube.com/watch?v=cgRmOpzgotI>

De acuerdo con Matemáticas profe Alex. (2022) la fórmula del teorema de Bayes se interpreta de la siguiente forma:

- $P(A|B)$ es la probabilidad de que la hipótesis A sea cierta dado que tenemos la evidencia B .
- $P(B|A)$ es la probabilidad de obtener la evidencia B si la hipótesis A es cierta.
- $P(A)$ es la probabilidad previa de que la hipótesis A sea cierta antes de obtener la evidencia B .
- $P(B)$ es la probabilidad total de observar la evidencia B .

Modalidades:

- **Aprendizaje bayesiano ingenuo o Naïve Bayes:** De acuerdo con la IBM documentation (2023), es una técnica antigua empleada para la clasificación y la selección de características predictivas.

Según IBM documentation (2021), detalla las características principales de este método:

- Es rápido y fácil de escalar, lo que implica que puede manejar grandes volúmenes de datos de manera eficiente.
- Opera calculando las probabilidades de que ocurra un resultado específico, considerando las distintas combinaciones de características (atributos) observadas en los datos de entrenamiento.
- Supone que cada característica contribuye de forma independiente a la probabilidad de que se produzca una clase específica, lo que permite calcular la probabilidad de una clase objetivo dado el conjunto de características observadas. Esto ofrece una medida de la probabilidad de que una instancia pertenezca a cada clase objetivo, considerando su conjunto de características.

IBM (2021) señala que para evaluar el desempeño del algoritmo que implementa el aprendizaje bayesiano ingenuo, se recurre a la validación cruzada, la cual verifica su precisión utilizando los mismos datos empleados en su entrenamiento.

Acorde con Kate Follis et al. (2023) los datos que se necesitan para trabajar con algoritmos que apliquen el aprendizaje bayesiano ingenuo son:

- Cada modelo debe incluir una columna con una única clave, ya sea numérica o de texto, que permita identificar de forma exclusiva cada registro.
- Todas las variables de entrada deben ser discretas o haberse discretizado previamente sus valores.
- Es esencial que las variables sean independientes entre sí. Esto significa que los atributos de entrada no deben estar correlacionados entre sí, especialmente cuando se utilizan para predecir resultados. Si dos columnas de datos están estrechamente relacionadas, esto puede sesgar el modelo al duplicar la influencia de esas columnas, ocultando así otros factores influyentes en el resultado.

Sin embargo, la capacidad del algoritmo para detectar correlaciones entre variables puede ser beneficiosa durante la exploración de un modelo o conjunto de datos para identificar relaciones entre las entradas.

- Se requiere al menos una columna de predicción en el conjunto de datos, donde el atributo de predicción debe consistir en valores discretos o haber sido previamente discretizados. Estos valores de la columna de predicción pueden tratarse como entradas para el modelo.

- **Redes neuronales bayesianas:**

Acorde con Laura Noreña(2023) las redes neuronales bayesianas funcionan de manera similar a las redes neuronales tradicionales, pero con una diferencia clave: en lugar de usar valores fijos para los pesos y sesgos de la red, se emplean distribuciones de probabilidad. Estas distribuciones son estimadas utilizando el algoritmo de inferencia bayesiana, lo que permite tener en cuenta la incertidumbre inherente en los datos y ajustar los parámetros de la red en consecuencia.

- **Máquinas de vectores de soporte bayesianas:**

Laura Noreña (2023) señala que las Máquinas Vectores de Soporte Bayesianas son una extensión de las Máquinas de Vectores de Soporte convencionales (SVM). Estas introducen distribuciones de probabilidad sobre los parámetros del modelo para capturar la incertidumbre, al igual que las redes neuronales bayesianas. En lugar de un único hiperplano de separación entre las clases, utilizan distribuciones de probabilidad para representar un conjunto de hiperplanos posibles. Durante el entrenamiento, estas distribuciones se ajustan mediante el algoritmo de inferencia bayesiana, considerando tanto los datos de entrenamiento como las distribuciones iniciales de los parámetros. Además, al hacer predicciones, proporcionan una medida de incertidumbre al calcular la probabilidad de que una instancia pertenezca a una clase específica, teniendo en cuenta las distribuciones de los parámetros y las características de la instancia.

- **Árboles de decisión bayesianos:**

Según Mauricio Mora (2023), los Árboles de Clasificación Bayesianos (BC-Trees) combinan la estructura jerárquica de los árboles de decisión con los principios de la teoría bayesiana. Mora también señala que los BC-Trees adoptan un enfoque probabilístico que toma en cuenta la incertidumbre durante el proceso de toma de decisiones.

A continuación, en la figura 2, se mostrará como son los árboles de decisión bayesianos:




Figura 2. Imagen de un árbol de decisión bayesiano. Calculadoras Online. (2022, October 7). Calculadora de Teorema de Bayes - Diagrama de arbol de probabilidad. <https://calculadorasonline.com/calculadora-de-teorema-de-bayes-diagrama-de-arbol-de-probabilidad/>

Aplicaciones del aprendizaje Bayesiano:

Acorde con Ciberseg. (2021) algunas aplicaciones del aprendizaje Bayesiano son :

- **Detección de fraude con tarjetas de crédito:**

La inferencia bayesiana es una herramienta poderosa para detectar patrones o indicios de fraude en transacciones con tarjetas de crédito mediante el análisis de datos y la inferencia de probabilidades mediante el teorema de Bayes. Una vez se detecta una actividad inusual, se informa a la gestión de riesgos empresariales, quienes emplean técnicas de red neuronal bayesiana en el conjunto de datos del perfil del cliente, que abarca sus transacciones financieras a lo largo del tiempo. Estos análisis permiten confirmar la presencia de actividades fraudulentas.

- **Filtrado de correo no deseado:**

La inferencia bayesiana, empleando el teorema de Bayes, permite la detección de correos no deseados mediante la construcción de un modelo capaz de determinar la probabilidad de que un correo electrónico sea spam. Este modelo, entrenado con el algoritmo bayesiano, considera la frecuencia de cada palabra en los mensajes de spam y no spam, asignándoles pesos correspondientes. Además, las redes neuronales bayesianas se utilizan para clasificar correos no deseados, evaluando características como el número y longitud de palabras, así como la presencia de caracteres específicos, para determinar la probabilidad de que un correo sea spam o no.

- **Diagnóstico médico:**

Se emplea para aprovechar datos de casos previos y calcular la probabilidad de que un paciente esté afectado por una enfermedad específica. La inferencia bayesiana sobresale frente a los métodos estadísticos convencionales al considerar todos los factores relevantes que pueden influir en el resultado, brindando probabilidades en lugar de simples resultados binarios, lo que facilita una predicción más precisa.

- **Ayuda a los robots a tomar decisiones:**

En robótica, la inferencia bayesiana desempeña un papel esencial al asistir a los robots en la toma de decisiones. Utilizando datos en tiempo real provenientes de los sensores del entorno del robot, se aplica el teorema de Bayes para inferir sus próximos movimientos o acciones, basándose en experiencias pasadas.

- **Reconstrucción de imágenes limpias a partir de imágenes ruidosas:** El teorema de Bayes encuentra aplicación en problemas inversos bayesianos, como la tomografía bayesiana. En este contexto, la

inferencia bayesiana se emplea para reconstruir imágenes a partir de versiones ruidosas de las mismas, utilizando tanto el teorema de Bayes como los algoritmos de Markov Chain Monte Carlo (MCMC).

Ejemplo:

Borrego, Á. (2021) proporciona el siguiente ejemplo en donde se aplica el aprendizaje Bayesiano:

El sistema consiste en analizar las características de los correos spam: quién es el emisor, número de destinatarios, existencia de archivos adjuntos, errores ortográficos, palabras que aparecen en el mensaje, etc.

Nos centraremos ahora en la aparición de palabras, por ejemplo, los términos «barato» y «comprar». En una muestra de 100 mensajes, observamos que 25 son spam y 75 no lo son. De los 25 mensajes que sí son spam, la palabra «barato» aparece en 20 de ellos. Entre los 75 que no son spam, la palabra «barato» aparece en 5 de ellos.

$$p(\text{barato} \mid \text{spam}) = 20/25 = 0,80$$

$$p(\text{barato} \mid \text{no spam}) = 5/75 = 0,066$$

En el caso de la palabra «comprar», su probabilidad de aparición en un mensaje de spam es 15/25 y en un mensaje que no sea spam de 10/75.

$$p(\text{comprar} \mid \text{spam}) = 15/25 = 0,60$$

$$p(\text{comprar} \mid \text{no spam}) = 10/75 = 0,133$$

Si suponemos que la aparición de las dos palabras son sucesos independientes, la probabilidad de que aparezcan conjuntamente será el producto de las

probabilidades individuales. Así, en el caso de los mensajes de spam, la probabilidad de que aparezcan juntas ambas palabras es la siguiente:

$$p(\text{barato y comprar} \mid \text{spam}) = 0,8 \times 0,6 = 0,48$$

La probabilidad es de 0,48, es decir, que 12 de cada 25 mensajes de spam contendrán las palabras «barato» y «comprar» simultáneamente.

Siguiendo el mismo procedimiento, podemos calcular la frecuencia conjunta de ambas palabras en mensajes que no sean spam. Vemos que la probabilidad es muy inferior, no llega ni a un correo electrónico de los 75:

$$p(\text{barato y comprar} \mid \text{no spam}) = 0,066 \times 0,133 = 0,009$$

Aplicando el teorema de Bayes ya podemos calcular la probabilidad de que un mensaje sea spam —o no lo sea— según la aparición de la palabra «barato», «comprar» o ambas.

$$p(\text{spam} \mid \text{barato}) = \frac{p(\text{barato} \mid \text{spam}) \times p(\text{spam})}{p(\text{barato})} = \frac{0,8 \times 0,25}{0,25} = 0,80$$

$$p(\text{spam} \mid \text{comprar}) = \frac{p(\text{comprar} \mid \text{spam}) \times p(\text{spam})}{p(\text{comprar})} = \frac{0,6 \times 0,25}{0,25} = 0,60$$

Finalmente, podemos calcular la posibilidad de que aparezcan las dos palabras conjuntamente:

$$\begin{aligned} & p(\text{spam} \mid \text{barato y comprar}) \\ &= \frac{p(\text{barato} \mid \text{spam}) \times p(\text{comprar} \mid \text{spam}) \times p(\text{spam})}{p(\text{barato} \mid \text{spam}) \times p(\text{comprar} \mid \text{spam}) \times p(\text{spam}) + p(\text{barato} \mid \text{nospam}) \times p(\text{comprar} \mid \text{nospam}) \times p(\text{nospam})} \\ &= \frac{(0,8 \times 0,6 \times 0,25)}{(0,8 \times 0,6 \times 0,25) + (0,066 \times 0,133 \times 0,75)} = 0,94 \end{aligned}$$

Es decir, según nuestro algoritmo, si un mensaje contiene las palabras «barato» y «comprar» hay un 94% de posibilidades de que sea spam (y 6% de que no lo sea).

Podemos ampliar la lista de palabras incluyendo, por ejemplo, la palabra «trabajo». Obviamente, a medida que añadimos palabras, las probabilidades de que aparezcan todas juntas se van reduciendo, pero es posible calcular la probabilidad de que aparezcan multiplicando las probabilidades de las palabras individuales. Supongamos que la palabra «trabajo» aparece en 5 de los mensajes que son spam y en 30 de los mensajes que no son spam de la muestra).

$$p(\text{trabajo} \mid \text{spam}) = 5/25 = 0,2$$

$$p(\text{trabajo} \mid \text{no spam}) = 30/75 = 0,4$$

Por tanto,

$$p() =$$

$$= \frac{0,8 \times 0,6 \times 0,2 \times 0,25}{(0,8 \times 0,6 \times 0,2 \times 0,25) + (0,066 \times 0,133 \times 0,4 \times 0,75)} = 0,90$$

En este caso, según nuestro algoritmo, si un mensaje contiene simultáneamente las palabras «barato», «comprar» y «trabajo» hay un 90% de posibilidades de que sea spam —y un 10% de probabilidades de que no lo sea—. La razón de la reducción del porcentaje respecto al caso anterior es que «trabajo» es una palabra asociada a mensajes que no son de spam.

Conclusión o reflexión final:

El aprendizaje bayesiano es una herramienta poderosa en la inteligencia artificial y la estadística. Nos ayuda a manejar la incertidumbre y ajustarnos a medida que obtenemos nueva información. Desde filtrar correos no deseados hasta ayudar en diagnósticos médicos y decisiones robóticas, su uso se extiende a diversas áreas. Con algoritmos como Naïve Bayes, redes neuronales bayesianas y árboles de decisión bayesianos, podemos hacer inferencias y tomar decisiones basadas en datos de manera más precisa. El ejemplo del filtrado de correos no deseados ilustra cómo se aplica en la práctica. Su habilidad para adaptarse y enfrentar nuevos desafíos asegura que continuará siendo esencial en el desarrollo de sistemas inteligentes y la resolución de problemas complejos en el futuro.

Referencia o bibliografía:

Borrego, Á. (2021, 2 noviembre). Capítulo 4 Clasificadores bayesianos | Introducción a la ciencia de datos para estudiantes de Información y Documentación. https://bookdown.org/angelborrego/ciencia_datos/clasificadores-bayesianos.html

Briega, R. E. L. (2017, 21 mayo). Introducción a la inferencia Bayesiana con Python. <https://relopezbriega.github.io/blog/2017/05/21/introduccion-a-la-inferencia-bayesiana-con-python/>

Caballero, M. M. (2023, 18 diciembre). Árboles de Clasificación Bayesianos en Arbolpedia. <https://www.linkedin.com/pulse/%C3%A1rboles-de-clasificaci%C3%B3n-bayesianos-en-arbolpedia-mora-caballero-b2xqe/>

Ciberseg. (2021, 9 noviembre). Teorema de Bayes en el aprendizaje automático: una guía importante. Ciberseguridad. https://ciberseguridad.com/guias/nuevas-tecnologias/machine-learning/teorema-bayes/#Ejemplos_de_aplicaciones_de_aprendizaje_automatgico_bayesiano

Follis, K. et al (2023, 23 diciembre). Algoritmo Bayes naive de Microsoft. Microsoft Learn. <https://learn.microsoft.com/es-es/analysis-services/data-mining/microsoft-naive-bayes-algorithm?view=asallproducts-allversions>

IBM documentation. (2021, August 17). <https://www.ibm.com/docs/es/spss-modeler/saas?topic=mining-oracle-naive-bayes>

IBM documentation. (s. f.). <https://www.ibm.com/docs/es/spss-statistics/saas?topic=edition-naive-bayes>

Inferencia bayesiana en el aprendizaje automático – Procesado Avanzado de Señales y Datos. (2023, 4 julio). <https://blogs.upm.es/pasd/2023/07/04/inferencia-bayesiana-en-el-aprendizaje-automatgico/>

Matemáticas profe Alex. (2022, 25 mayo). Teorema de Bayes | Introducción [Vídeo]. YouTube. <https://www.youtube.com/watch?v=bDfCURXoKkU>